

Propiedades de Matrices: Suma, Multiplicación, Identidad y Transpuesta

Matemáticas para Inteligencia Artificial — Unidad I

Índice

1. ¿Qué es una matriz?	2
2. Suma de matrices	2
3. Multiplicación por un escalar	2
4. Multiplicación de matrices	2
4.1. La regla	2
4.2. Cuidado: el orden importa	3
4.3. Cuidado: no es lo mismo que multiplicar “entrada por entrada”	3
4.4. Propiedades	3
5. La matriz identidad	4
6. La transpuesta	4
6.1. Matrices simétricas	4
7. Ejercicios propuestos	5
8. Aplicaciones en Inteligencia Artificial y Machine Learning	6
8.1. Multiplicación de matrices: el corazón de una red neuronal	6
8.2. Transpuesta: cómo se propagan los gradientes	6
8.3. Matriz identidad: conexiones residuales	6
8.4. Suma de matrices: promediar modelos y gradientes	6

Basado en: Deisenroth, M. P., Faisal, A. A., & Ong, C. S. (2020). Mathematics for Machine Learning. Cambridge University Press, Sección 2.2.

1. ¿Qué es una matriz?

Una matriz es simplemente un arreglo rectangular de números, ordenado en filas y columnas. Si tiene m filas y n columnas, decimos que es de tamaño $m \times n$.

$$A = \begin{bmatrix} 1 & 2 & 3 \\ 4 & 5 & 6 \end{bmatrix} \text{ es una matriz de } 2 \times 3 \text{ (2 filas, 3 columnas)}$$

2. Suma de matrices

Se suman **entrada por entrada**. Solo se pueden sumar matrices del **mismo tamaño**.

Ejemplo. $A = \begin{bmatrix} 1 & 2 \\ 3 & 4 \end{bmatrix}, B = \begin{bmatrix} 5 & 0 \\ 1 & 2 \end{bmatrix}:$

$$A + B = \begin{bmatrix} 1+5 & 2+0 \\ 3+1 & 4+2 \end{bmatrix} = \begin{bmatrix} 6 & 2 \\ 4 & 6 \end{bmatrix}$$

Propiedades. Para A, B, C del mismo tamaño:

- **Conmutativa:** $A + B = B + A$ (el orden no importa).
- **Asociativa:** $(A + B) + C = A + (B + C)$ (no importa cómo se agrupen).

3. Multiplicación por un escalar

Se multiplica **cada entrada** por el número.

Ejemplo. Con $\lambda = 3$ y $A = \begin{bmatrix} 1 & 2 \\ 3 & 4 \end{bmatrix}:$

$$3A = \begin{bmatrix} 3(1) & 3(2) \\ 3(3) & 3(4) \end{bmatrix} = \begin{bmatrix} 3 & 6 \\ 9 & 12 \end{bmatrix}$$

Propiedades. Para $\lambda, \psi \in \mathbb{R}$ y B, C matrices del mismo tamaño:

- **Asociativa:** $(\lambda\psi)C = \lambda(\psi C)$.
- **Distributiva:** $(\lambda + \psi)C = \lambda C + \psi C, \quad \lambda(B + C) = \lambda B + \lambda C$.

4. Multiplicación de matrices

4.1. La regla

Esta es la operación que más cuesta al principio. La idea: cada entrada del resultado se obtiene combinando **una fila completa** de la primera matriz con **una columna completa** de la segunda (multiplicando posición a posición y sumando).

Requisito de tamaños. Para multiplicar $A \cdot B$, el número de **columnas** de A debe ser igual al número de **filas** de B :

$$\underbrace{A}_{m \times n} \underbrace{B}_{n \times k} = \underbrace{C}_{m \times k}$$

Ejemplo, paso a paso. $A = \begin{bmatrix} 1 & 2 \\ 3 & 4 \end{bmatrix}$, $B = \begin{bmatrix} 2 & 0 \\ 1 & 2 \end{bmatrix}$:

- Entrada (1, 1) de AB : fila 1 de A con columna 1 de B : $(1)(2) + (2)(1) = 4$
- Entrada (1, 2) de AB : fila 1 de A con columna 2 de B : $(1)(0) + (2)(2) = 4$
- Entrada (2, 1) de AB : fila 2 de A con columna 1 de B : $(3)(2) + (4)(1) = 10$
- Entrada (2, 2) de AB : fila 2 de A con columna 2 de B : $(3)(0) + (4)(2) = 8$

$$AB = \begin{bmatrix} 4 & 4 \\ 10 & 8 \end{bmatrix}$$

4.2. Cuidado: el orden importa

A diferencia de multiplicar números, en matrices $AB \neq BA$ **en general**. Con las mismas A, B de arriba:

$$BA = \begin{bmatrix} 2 & 4 \\ 7 & 10 \end{bmatrix} \neq \begin{bmatrix} 4 & 4 \\ 10 & 8 \end{bmatrix} = AB$$

4.3. Cuidado: no es lo mismo que multiplicar “entrada por entrada”

Si simplemente multiplicaras cada entrada de A por la entrada correspondiente de B (como en muchos lenguajes de programación al usar `*` directamente sobre arreglos), obtendrías algo distinto:

$$A * B = \begin{bmatrix} (1)(2) & (2)(0) \\ (3)(1) & (4)(2) \end{bmatrix} = \begin{bmatrix} 2 & 0 \\ 3 & 8 \end{bmatrix} \neq AB = \begin{bmatrix} 4 & 4 \\ 10 & 8 \end{bmatrix}$$

Esa operación “entrada por entrada” sí existe y se llama **producto de Hadamard**, pero es **distinta** de la multiplicación de matrices que acabamos de definir (que es la que usa el álgebra lineal). En NumPy, por ejemplo, `A * B` da el producto de Hadamard, mientras que `A @ B` o `np.matmul(A, B)` da la multiplicación de matrices real.

4.4. Propiedades

Para matrices de tamaños compatibles:

- **Asociativa:** $(AB)C = A(BC)$.
- **Distributiva:** $(A + B)C = AC + BC$, $A(C + D) = AC + AD$.
- **Multiplicación con la identidad:** $I_m A = A I_n = A$ (para $A \in \mathbb{R}^{m \times n}$).

Nota: la conmutativa **no** está en esta lista a propósito —ya vimos que, en general, $AB \neq BA$.

5. La matriz identidad

Es la matriz cuadrada con 1 en la diagonal y 0 en todo lo demás. Se comporta como el número 1: multiplicar por ella no cambia nada.

$$I_2 = \begin{bmatrix} 1 & 0 \\ 0 & 1 \end{bmatrix}$$

Ejemplo. Con $A = \begin{bmatrix} 3 & 5 \\ 2 & 7 \end{bmatrix}$:

$$AI_2 = I_2A = \begin{bmatrix} 3 & 5 \\ 2 & 7 \end{bmatrix} = A$$

6. La transpuesta

Transponer una matriz significa **convertir sus filas en columnas** (y sus columnas en filas). Se denota $A^\top$.

Ejemplo. $A = \begin{bmatrix} 1 & 2 & 3 \\ 4 & 5 & 6 \end{bmatrix}$ (tamaño 2×3):

$$A^\top = \begin{bmatrix} 1 & 4 \\ 2 & 5 \\ 3 & 6 \end{bmatrix} \quad (\text{tamaño } 3 \times 2)$$

La primera fila de A se convirtió en la primera columna de $A^\top$, y así sucesivamente.

Propiedades.

- $(A^\top)^\top = A$ (transponer dos veces regresa a la matriz original).
- $(A + B)^\top = A^\top + B^\top$.
- $(AB)^\top = B^\top A^\top$ —**el orden se invierte**. Por ejemplo, con $A = \begin{bmatrix} 1 & 2 \\ 3 & 4 \end{bmatrix}$, $B = \begin{bmatrix} 2 & 0 \\ 1 & 2 \end{bmatrix}$ (las mismas de la Sección 4):

$$(AB)^\top = \begin{bmatrix} 4 & 10 \\ 4 & 8 \end{bmatrix} = B^\top A^\top \quad \neq \quad A^\top B^\top = \begin{bmatrix} 2 & 7 \\ 4 & 10 \end{bmatrix}$$

6.1. Matrices simétricas

Una matriz cuadrada es **simétrica** si es igual a su propia transpuesta: $A = A^\top$.

Ejemplo. $A = \begin{bmatrix} 2 & 1 \\ 1 & 2 \end{bmatrix}$: intercambiar filas y columnas da la misma matriz $\Rightarrow A$ es simétrica. (Esta es la misma matriz que usamos en el documento de autovalores y autovectores, donde vimos que las matrices simétricas tienen propiedades especiales.)

7. Ejercicios propuestos

Ejercicio 1. Calcula $A + B$ con $A = \begin{bmatrix} 2 & -1 \\ 0 & 3 \end{bmatrix}$, $B = \begin{bmatrix} 1 & 4 \\ 5 & -2 \end{bmatrix}$.

Solución. $A + B = \begin{bmatrix} 3 & 3 \\ 5 & 1 \end{bmatrix}$.

Ejercicio 2. Calcula AB con $A = \begin{bmatrix} 2 & 1 \\ 0 & 3 \end{bmatrix}$, $B = \begin{bmatrix} 1 & 2 \\ 4 & 0 \end{bmatrix}$.

Solución. Entrada $(1, 1)$: $(2)(1) + (1)(4) = 6$. Entrada $(1, 2)$: $(2)(2) + (1)(0) = 4$. Entrada $(2, 1)$: $(0)(1) + (3)(4) = 12$. Entrada $(2, 2)$: $(0)(2) + (3)(0) = 0$.

$$AB = \begin{bmatrix} 6 & 4 \\ 12 & 0 \end{bmatrix}$$

Ejercicio 3. Encuentra la transpuesta de $A = \begin{bmatrix} 5 & -2 \\ 0 & 1 \\ 3 & 4 \end{bmatrix}$.

Solución. $A^T = \begin{bmatrix} 5 & 0 & 3 \\ -2 & 1 & 4 \end{bmatrix}$.

Ejercicio 4. ¿Es $A = \begin{bmatrix} 1 & 3 \\ 3 & 1 \end{bmatrix}$ simétrica?

Solución. $A^T = \begin{bmatrix} 1 & 3 \\ 3 & 1 \end{bmatrix} = A$. **Sí** es simétrica.

8. Aplicaciones en Inteligencia Artificial y Machine Learning

8.1. Multiplicación de matrices: el corazón de una red neuronal

Cada capa de una red neuronal calcula $y = Wx + b$, donde W es una matriz de pesos y x es el vector de entrada. Esa multiplicación Wx es exactamente la operación que acabamos de definir —cuando entrenas un modelo, todo lo que hace la GPU, millones de veces por segundo, es multiplicación de matrices.

8.2. Transpuesta: cómo se propagan los gradientes

Durante el entrenamiento (*backpropagation*), el error se propaga hacia atrás usando la matriz de pesos **transpuesta**, $W^\top$. También aparece en la solución de mínimos cuadrados que ya vimos, $\theta = (X^\top X)^{-1} X^\top y$.

8.3. Matriz identidad: conexiones residuales

Las redes neuronales muy profundas (como ResNet) usan “conexiones residuales”: en vez de que cada capa transforme completamente su entrada, calcula $y = x + F(x)$ —la parte “ x ” funciona como una multiplicación implícita por la identidad, dejando pasar la información sin modificarla, lo cual ayuda a entrenar redes de cientos de capas.

8.4. Suma de matrices: promediar modelos y gradientes

El entrenamiento distribuido (*federated learning*) y el descenso de gradiente por lotes dependen de poder **sumar** (y promediar) matrices de pesos o de gradientes —la operación más simple de todas, pero indispensable.