

Notas de estudio: Vectores y Espacios Vectoriales

Representación de datos, operaciones vectoriales y propiedades de los espacios vectoriales

Matemáticas para Inteligencia Artificial — Unidad I

Índice

1. Grupos	2
1.1. Definición	2
1.2. Ejemplos (verificando cada caso)	2
1.3. El grupo lineal general	3
2. Espacios vectoriales	4
2.1. Definición	4
2.2. Ejemplos	4
3. Subespacios vectoriales	5
3.1. Definición y criterio práctico	5
3.2. Ejemplos	5
4. Ejercicios propuestos	7
4.1. Grupos	7
4.2. Espacios vectoriales	7
4.3. Subespacios vectoriales	7
5. Aplicaciones en Inteligencia Artificial y Machine Learning	8
5.1. Espacios vectoriales: representación de datos y descenso de gradiente	8
5.2. Espacio vectorial de matrices: promediar modelos	8
5.3. Subespacios: reducción de dimensionalidad (PCA)	8
5.4. Grupos: transformaciones invertibles en modelos generativos	8

Basado en: Deisenroth, M. P., Faisal, A. A., & Ong, C. S. (2020). Mathematics for Machine Learning. Cambridge University Press, Sección 2.4 (“Vector Spaces”).

1. Grupos

1.1. Definición

Cómo leer la notación que sigue. Usaremos letras caligráficas como $\mathcal{G}$ para denotar conjuntos abstractos (podrían ser números, vectores, matrices, o cualquier otro tipo de objeto). El símbolo $\forall$ se lee “para todo” y $\exists$ se lee “existe”. La expresión $x \in \mathcal{G}$ se lee “ x pertenece a $\mathcal{G}$ ” (es decir, x es un elemento del conjunto $\mathcal{G}$); su contraparte $x \notin \mathcal{G}$ se lee “ x no pertenece a $\mathcal{G}$ ”. El símbolo $\otimes$ representa una operación **genérica** —no necesariamente una multiplicación—: puede ser una suma, una resta, o cualquier regla que combine dos elementos del conjunto para producir otro elemento del mismo conjunto.

Definición 2.7 (Grupo). Sea $\mathcal{G}$ un conjunto y $\otimes : \mathcal{G} \times \mathcal{G} \rightarrow \mathcal{G}$ una operación. $G := (\mathcal{G}, \otimes)$ es un **grupo** si:

1. **Cerradura:** $\forall x, y \in \mathcal{G} : x \otimes y \in \mathcal{G}$
2. **Asociatividad:** $\forall x, y, z \in \mathcal{G} : (x \otimes y) \otimes z = x \otimes (y \otimes z)$
3. **Elemento neutro:** $\exists e \in \mathcal{G} \forall x \in \mathcal{G} : x \otimes e = x = e \otimes x$
4. **Elemento inverso:** $\forall x \in \mathcal{G} \exists y \in \mathcal{G} : x \otimes y = e = y \otimes x$ (este elemento se denota x^{-1} , y se lee “ x inverso”)

Si además $\forall x, y \in \mathcal{G} : x \otimes y = y \otimes x$, se dice que G es un **grupo abeliano** (conmutativo).

Observación: el “elemento inverso” se define respecto a la operación $\otimes$; no significa necesariamente $\frac{1}{x}$.

1.2. Ejemplos (verificando cada caso)

Antes de los ejemplos: $\mathbb{Z}$ denota el conjunto de los números enteros, $\mathbb{N}_0$ los números naturales incluyendo el cero, y $\mathbb{R}$ los números reales —la letra con “doble trazo” (de pizarrón) es la convención estándar para denotar estos conjuntos numéricos.

$(\mathbb{Z}, +)$ **es abeliano.** Cerradura: la suma de enteros es entero. Neutro: 0. Inverso de x : $-x$. Conmutativa. ✓

$(\mathbb{N}_0, +)$ **NO es grupo.** Tiene neutro (0), pero le faltan inversos: por ejemplo, $3 \in \mathbb{N}_0$ no tiene inverso, porque $-3 \notin \mathbb{N}_0$.

$(\mathbb{Z}, \cdot)$ **NO es grupo.** Tiene neutro (1), pero le faltan inversos: por ejemplo, $2 \in \mathbb{Z}$ no tiene inverso multiplicativo entero, porque $\frac{1}{2} \notin \mathbb{Z}$.

$(\mathbb{R} \setminus \{0\}, \cdot)$ **es abeliano.** Al excluir el 0 se evita el único elemento sin inverso multiplicativo.

$(\mathbb{R}^n, +)$ **es abeliano.** Con suma componente a componente. Ejemplo ($n = 2$): $(1, 3) + (2, -1) = (3, 2) = (2, -1) + (1, 3)$. Neutro: $(0, 0)$. Inverso de (x_1, x_2) : $(-x_1, -x_2)$.

$(\mathbb{R}^{m \times n}, +)$ **es abeliano.** ($\mathbb{R}^{m \times n}$ denota el conjunto de todas las matrices con m filas, n columnas y entradas reales.) Análogamente, con suma entrada a entrada.

$(\mathbb{R}^{n \times n}, \cdot)$: **aquí hay que tener cuidado.** Cerradura y asociatividad vienen directo de la definición de multiplicación de matrices. Verificación numérica de la asociatividad con $A = \begin{bmatrix} 1 & 2 \\ 0 & 1 \end{bmatrix}$, $B = \begin{bmatrix} 2 & 0 \\ 1 & 3 \end{bmatrix}$,

$$C = \begin{bmatrix} 1 & 1 \\ 2 & 0 \end{bmatrix}:$$

$$(AB)C = \begin{bmatrix} 16 & 4 \\ 7 & 1 \end{bmatrix} = A(BC) \quad \checkmark \quad (1)$$

El neutro es I_n . Pero el **inverso solo existe si A es invertible**. Por lo tanto, $(\mathbb{R}^{n \times n}, \cdot)$ **no es un grupo** en general —a las matrices singulares les falta inverso, exactamente como vimos con $\begin{bmatrix} 1 & 2 \\ 2 & 4 \end{bmatrix}$ en la sección de rango. Solo el subconjunto de matrices invertibles forma un grupo.

1.3. El grupo lineal general

Definición 2.8 (Grupo lineal general). El conjunto de matrices invertibles (regulares) $A \in \mathbb{R}^{n \times n}$ es un grupo respecto a la multiplicación de matrices, llamado **grupo lineal general** $GL(n, \mathbb{R})$. No es abeliano, porque la multiplicación de matrices no es conmutativa en general:

$$AB = \begin{bmatrix} 4 & 6 \\ 1 & 3 \end{bmatrix} \neq \begin{bmatrix} 2 & 4 \\ 1 & 5 \end{bmatrix} = BA \quad (2)$$

2. Espacios vectoriales

2.1. Definición

Definición 2.9 (Espacio vectorial). Un espacio vectorial real $V = (\mathcal{V}, +, \cdot)$ es un conjunto $\mathcal{V}$ con dos operaciones $+: \mathcal{V} \times \mathcal{V} \rightarrow \mathcal{V}$ y $\cdot: \mathbb{R} \times \mathcal{V} \rightarrow \mathcal{V}$, tales que:

1. $(\mathcal{V}, +)$ es un grupo abeliano.

2. **Distributividad:**

$$a) \quad \forall \lambda \in \mathbb{R}, x, y \in \mathcal{V} : \lambda \cdot (x + y) = \lambda \cdot x + \lambda \cdot y$$

$$b) \quad \forall \lambda, \psi \in \mathbb{R}, x \in \mathcal{V} : (\lambda + \psi) \cdot x = \lambda \cdot x + \psi \cdot x$$

3. **Asociatividad (operación externa):** $\forall \lambda, \psi \in \mathbb{R}, x \in \mathcal{V} : \lambda \cdot (\psi \cdot x) = (\lambda\psi) \cdot x$

4. **Elemento neutro externo:** $\forall x \in \mathcal{V} : 1 \cdot x = x$

Terminología: de aquí en adelante escribiremos V en vez de $\mathcal{V}$ para simplificar la notación (es decir, $x \in V$ significa lo mismo que $x \in \mathcal{V}$). Los elementos $x \in V$ son **vectores**; el neutro de $(\mathcal{V}, +)$ es el **vector cero**, denotado **0 en negritas** para distinguirlo del número escalar 0; $+$ es la **suma vectorial**; los $\lambda \in \mathbb{R}$ son **escalares**; $\cdot$ es la **multiplicación por escalares**.

Verificación numérica de los axiomas. Con $x = (1, 2)$, $y = (3, -1)$, $\lambda = 2$, $\psi = 3$ en $\mathbb{R}^2$:

$$\lambda(x + y) = 2(4, 1) = (8, 2) = 2(1, 2) + 2(3, -1) = \lambda x + \lambda y \quad \checkmark \quad (3)$$

$$(\lambda + \psi)x = 5(1, 2) = (5, 10) = 2(1, 2) + 3(1, 2) = \lambda x + \psi x \quad \checkmark \quad (4)$$

$$\lambda(\psi x) = 2(3, 6) = (6, 12) = 6(1, 2) = (\lambda\psi)x \quad \checkmark \quad (5)$$

Nota importante: la “multiplicación de vectores” no está definida. Para $a, b \in \mathbb{R}^n$, un producto ab elemento a elemento (común en programación) no tiene sentido con las reglas usuales de multiplicación de matrices. Lo que sí está definido, viendo los vectores como matrices $n \times 1$:

- $ab^\top \in \mathbb{R}^{n \times n}$: **producto externo** (*outer product*)
- $a^\top b \in \mathbb{R}$: **producto interno/escalar/punto**

2.2. Ejemplos

Ejemplo 2.11.

- $V = \mathbb{R}^n$: suma y multiplicación por escalar componente a componente.
- $V = \mathbb{R}^{m \times n}$: suma y multiplicación por escalar entrada a entrada (equivalente a $\mathbb{R}^{mn}$).
- $V = \mathbb{C}$: con la suma estándar de números complejos.

3. Subespacios vectoriales

3.1. Definición y criterio práctico

Cómo leer la notación. $\mathcal{U} \subseteq \mathcal{V}$ se lee “ $\mathcal{U}$ es subconjunto de $\mathcal{V}$ ” (todo elemento de $\mathcal{U}$ es también elemento de $\mathcal{V}$); $\emptyset$ denota el **conjunto vacío** (el conjunto que no tiene ningún elemento).


Definición 2.10 (Subespacio vectorial). Sea $V = (\mathcal{V}, +, \cdot)$ un espacio vectorial y $\mathcal{U} \subseteq \mathcal{V}$, $\mathcal{U} \neq \emptyset$. Entonces $U = (\mathcal{U}, +, \cdot)$ es **subespacio** de V si U es un espacio vectorial con las operaciones de V restringidas a $\mathcal{U}$.

Como $\mathcal{U}$ hereda directamente de V las propiedades de grupo abeliano, distributividad, asociatividad y neutro externo, en la práctica **basta verificar**:

1. $\mathbf{0} \in \mathcal{U}$ (en particular, $\mathcal{U} \neq \emptyset$).
2. Cerradura bajo la operación externa: $\forall \lambda \in \mathbb{R} \forall x \in \mathcal{U} : \lambda x \in \mathcal{U}$.
3. Cerradura bajo la operación interna: $\forall x, y \in \mathcal{U} : x + y \in \mathcal{U}$.

3.2. Ejemplos

Consideremos cuatro subconjuntos de $\mathbb{R}^2$:



$A = \{(x, y) : 0 \leq x \leq 1, 0 \leq y \leq 1\}$ (**cuadrado**). No cerrado bajo escalar: $(1, 1) \in A$, pero $2(1, 1) = (2, 2) \notin A$. **No** es subespacio.

$B = \{(x, y) : y = x + 1\}$ (**recta que no pasa por el origen**). $\mathbf{0} = (0, 0) \notin B$ (pues $0 \neq 0 + 1$). **No** es subespacio.

$C = \{(x, y) : x \geq 0, y \geq 0\}$ (**primer cuadrante**). Cerrado bajo suma y escalares **no negativos**, pero no bajo escalares negativos: $(1, 1) \in C$, pero $-1 \cdot (1, 1) = (-1, -1) \notin C$. **No** es subespacio.

$D = \{(x, y) : y = 2x\}$ (**recta por el origen**). Contiene $\mathbf{0}$; cerrado bajo suma: $(x_1, 2x_1) + (x_2, 2x_2) = (x_1 + x_2, 2(x_1 + x_2)) \in D$; cerrado bajo escalar: $\lambda(x, 2x) = (\lambda x, 2\lambda x) \in D$. **✓ Sí** es subespacio.

El espacio nulo $N(A)$ siempre es subespacio. Contiene a $\mathbf{0}$ (pues $A\mathbf{0} = \mathbf{0}$), y es cerrado bajo ambas operaciones: si $x_h, x'_h \in N(A)$, entonces $A(\lambda_1 x_h + \lambda_2 x'_h) = \lambda_1 A x_h + \lambda_2 A x'_h = \lambda_1 \mathbf{0} + \lambda_2 \mathbf{0} = \mathbf{0}$, así que cualquier combinación $\lambda_1 x_h + \lambda_2 x'_h$ también está en $N(A)$.

La solución de $Ax = b$ con $b \neq \mathbf{0}$ NO es subespacio. Con $A = \begin{bmatrix} 1 & 2 \\ 2 & 4 \end{bmatrix}$, $b = (1, 2)$: $x_1 = (1, 0)$ y $x_2 = x_1 + (-2, 1) = (-1, 1)$ son ambas soluciones ($Ax_1 = Ax_2 = (1, 2)$). Pero

$$x_1 + x_2 = (0, 1), \quad A(x_1 + x_2) = (2, 4) \neq b \quad (6)$$

La suma de dos soluciones **no es solución** —el conjunto no es cerrado, y tampoco contiene $\mathbf{0}$ (a menos que $b = \mathbf{0}$).

La intersección de subespacios es subespacio. Con $U_1 = \{(x, y, z) : x = 0\}$ y $U_2 = \{(x, y, z) : y = 0\}$ en $\mathbb{R}^3$: $U_1 \cap U_2 = \{(x, y, z) : x = 0, y = 0\}$ es el eje z —una recta por el origen, que es subespacio.

4. Ejercicios propuestos

4.1. Grupos

Ejercicio 1. ¿Es $(2\mathbb{Z}, +)$ —los enteros pares, con la suma— un grupo?

Solución. **Cerradura:** par + par = par. **Asociatividad:** heredada de $(\mathbb{Z}, +)$. **Neutro:** $0 \in 2\mathbb{Z}$. **Inverso:** de $2k$ es $-2k \in 2\mathbb{Z}$. Además es conmutativo. **Sí, es un grupo abeliano.**

Ejercicio 2. ¿Es $(\mathbb{R}^{2 \times 2}, \cdot)$ (matrices 2×2 con la multiplicación de matrices) un grupo?

Solución. La matriz $A = \begin{bmatrix} 1 & 0 \\ 0 & 0 \end{bmatrix}$ tiene $\det(A) = 0$, así que es singular y no tiene inverso. Como no todos los elementos tienen inverso, **no es un grupo** (aunque sí cumple cerradura, asociatividad y tiene neutro I_2).

4.2. Espacios vectoriales

Ejercicio 1. Verificar la distributividad $\lambda(x + y) = \lambda x + \lambda y$ en $\mathbb{R}^3$ con $x = (1, 0, 2)$, $y = (-1, 3, 1)$, $\lambda = 2$.

Solución.

$$\lambda(x + y) = 2(0, 3, 3) = (0, 6, 6) \quad (7)$$

$$\lambda x + \lambda y = (2, 0, 4) + (-2, 6, 2) = (0, 6, 6) \quad \checkmark \quad (8)$$

Ejercicio 2. ¿Es el conjunto de polinomios de grado **exactamente** 2 (con la suma usual de polinomios) un espacio vectorial?

Solución. Tomemos $p(x) = x^2 + 1$ y $q(x) = -x^2 + 3$, ambos de grado exactamente 2.

$$p(x) + q(x) = 4 \quad (9)$$

El resultado es un polinomio de grado 0, que **no** pertenece al conjunto. Falla la cerradura bajo la suma $\Rightarrow$ (símbolo que se lee “por lo tanto” o “implica que”) **no** es un espacio vectorial. (El conjunto de polinomios de grado *menor o igual* a 2 sí lo sería.)

4.3. Subespacios vectoriales

Ejercicio 1. ¿Es $U = \{(x, y, z) \in \mathbb{R}^3 : x + y + z = 0\}$ un subespacio de $\mathbb{R}^3$?

Solución. **Contiene 0:** $0 + 0 + 0 = 0 \quad \checkmark$. **Cerradura bajo escalar:** si $x + y + z = 0$, entonces $\lambda x + \lambda y + \lambda z = \lambda(x + y + z) = 0 \quad \checkmark$. **Cerradura bajo suma:** si (x_1, y_1, z_1) y (x_2, y_2, z_2) están en U , su suma cumple $(x_1 + x_2) + (y_1 + y_2) + (z_1 + z_2) = 0 + 0 = 0 \quad \checkmark$. **Sí es subespacio** (es exactamente $N(A)$ con $A = [1, 1, 1]$).

Ejercicio 2. ¿Es $U = \{(x, y) \in \mathbb{R}^2 : xy \geq 0\}$ un subespacio de $\mathbb{R}^2$?

Solución. Tomemos $a = (2, 1) \in U$ (pues $2 \cdot 1 = 2 \geq 0$) y $b = (-1, -3) \in U$ (pues $(-1)(-3) = 3 \geq 0$).

$$a + b = (1, -2), \quad 1 \cdot (-2) = -2 < 0 \quad (10)$$

La suma sale de U . **No** es subespacio (aunque contiene a **0**).

5. Aplicaciones en Inteligencia Artificial y Machine Learning

5.1. Espacios vectoriales: representación de datos y descenso de gradiente

Todo dato en machine learning —una imagen, un vector de características, los parámetros de un modelo— se representa como un vector en algún $\mathbb{R}^n$, y absolutamente toda la maquinaria de optimización depende de que $\mathbb{R}^n$ sea un espacio vectorial. La regla de actualización del descenso de gradiente,

$$\theta_{t+1} = \theta_t - \eta \nabla L(\theta_t), \quad (11)$$

es literalmente una operación de espacio vectorial: resta de vectores (θ_t menos otro vector) y multiplicación por un escalar (la tasa de aprendizaje η). Sin la estructura de espacio vectorial, esta actualización ni siquiera estaría bien definida.

5.2. Espacio vectorial de matrices: promediar modelos

Como $\mathbb{R}^{m \times n}$ es un espacio vectorial, tiene sentido **sumar y promediar matrices de pesos** de distintos modelos entrenados. Esto es exactamente lo que hacen técnicas como *federated learning* (promediar los pesos entrenados en distintos dispositivos) y *model soups* (promediar varios modelos afinados para mejorar el desempeño): $W_{\text{prom}} = \frac{1}{k}(W_1 + W_2 + \dots + W_k)$, una operación que solo tiene sentido porque las matrices de pesos viven en un espacio vectorial.

5.3. Subespacios: reducción de dimensionalidad (PCA)

Los subespacios vectoriales son una idea clave en machine learning para reducción de dimensionalidad. El **Análisis de Componentes Principales (PCA)** busca el subespacio de dimensión $k < n$ que mejor captura la variabilidad de los datos, y luego proyecta cada punto sobre ese subespacio —comprimiendo los datos mientras se conserva la mayor información posible. Que la proyección cumpla las propiedades de subespacio (contener el origen, cerradura bajo suma y escalar) es justamente lo que garantiza que las combinaciones lineales de datos comprimidos sigan siendo válidas dentro del subespacio reducido.

5.4. Grupos: transformaciones invertibles en modelos generativos

Los *normalizing flows* (una familia de modelos generativos) construyen una distribución de probabilidad compleja aplicando una secuencia de transformaciones **invertibles** a una distribución simple. Cada capa lineal de la transformación debe tener una matriz de pesos que pertenezca al **grupo lineal general** $GL(n, \mathbb{R})$ —es decir, debe ser invertible—, porque el modelo necesita poder revertir la transformación exactamente para evaluar la densidad de probabilidad. Esta es una razón muy concreta por la que la distinción entre “matriz cualquiera” y “matriz en $GL(n, \mathbb{R})$ ” —el mismo tema que vimos con matrices singulares— importa directamente en el diseño de arquitecturas de redes neuronales.