

Notas de estudio: Determinante, Norma, Producto Punto y Ortogonalidad

Matemáticas para Inteligencia Artificial — Unidad I

Índice

1. El determinante	2
1.1. ¿Qué es?	2
1.2. Cómo se calcula: matrices 2×2	2
1.3. Significado geométrico	2
1.4. Cómo se calcula: matrices 3×3	3
1.5. Propiedades que usaremos después	3
2. Norma euclidiana	3
2.1. ¿Qué es?	3
2.2. Fórmula	3
3. Producto punto (producto interno)	4
3.1. ¿Qué es?	4
3.2. Fórmula	4
3.3. Significado geométrico: mide qué tan alineados están dos vectores	4
3.4. El caso especial: producto punto igual a cero	4
4. Ortogonalidad y matrices ortogonales	5
4.1. Vectores ortogonales, unitarios y ortonormales	5
4.2. Matriz ortogonal	5
4.3. La propiedad más útil: no hace falta Gauss-Jordan para invertirla	5
5. Ejercicios propuestos	6
5.1. Determinante	6
5.2. Norma y producto punto	6
5.3. Ortogonalidad	6
6. Aplicaciones en Inteligencia Artificial y Machine Learning	6
6.1. Producto punto: similitud del coseno y mecanismos de atención	6
6.2. Norma: regularización de modelos	6
6.3. Matrices ortogonales: estabilidad en redes neuronales profundas	7
6.4. Determinante: modelos generativos (<i>normalizing flows</i>)	7

Basado en: Deisenroth, M. P., Faisal, A. A., & Ong, C. S. (2020). Mathematics for Machine Learning. Cambridge University Press, Secciones 3.1–3.4 y 4.1.

1. El determinante

1.1. ¿Qué es?

El determinante es un solo número que se calcula a partir de una matriz **cuadrada**, y que resume dos cosas muy útiles sobre ella:

- Te dice si la matriz tiene inversa o no (si el determinante es 0, no la tiene).
- Te dice por qué factor la transformación que representa esa matriz **escala áreas o volúmenes**.

Se denota $\det(A)$ o, alternativamente, con barras verticales: $|A|$.

1.2. Cómo se calcula: matrices 2×2

Para $A = \begin{bmatrix} a & b \\ c & d \end{bmatrix}$:


$$\det(A) = ad - bc$$

Ejemplo. $A = \begin{bmatrix} 3 & 1 \\ 2 & 4 \end{bmatrix}$:

$$\det(A) = (3)(4) - (1)(2) = 12 - 2 = 10$$

1.3. Significado geométrico

Toma las dos columnas de A como vectores: $(3, 2)$ y $(1, 4)$. Si dibujas el paralelogramo que forman esos dos vectores, su **área es exactamente** $|\det(A)| = 10$.



Si las dos columnas fueran **paralelas** (o una fuera múltiplo de la otra), el paralelogramo se “aplastaría” en una línea, con área 0 —y en ese caso $\det(A) = 0$. Esto conecta directo con algo que ya vimos: columnas paralelas o múltiplos son **linealmente dependientes**, y una matriz con columnas dependientes no tiene inversa. Por eso:

$$\det(A) = 0 \iff A \text{ es singular (no tiene inversa)} \iff \text{las columnas de } A \text{ son dependientes}$$

Ejemplo. $B = \begin{bmatrix} 1 & 2 \\ 2 & 4 \end{bmatrix}$: $\det(B) = (1)(4) - (2)(2) = 0$ —confirma numéricamente lo que ya sabíamos.

1.4. Cómo se calcula: matrices 3×3

Para $A = \begin{bmatrix} a_{11} & a_{12} & a_{13} \\ a_{21} & a_{22} & a_{23} \\ a_{31} & a_{32} & a_{33} \end{bmatrix}$, una forma práctica de recordar la fórmula (regla de Sarrus) es:

$$\det(A) = a_{11}a_{22}a_{33} + a_{12}a_{23}a_{31} + a_{13}a_{21}a_{32} - a_{13}a_{22}a_{31} - a_{11}a_{23}a_{32} - a_{12}a_{21}a_{33}$$

Ejemplo. $A = \begin{bmatrix} 2 & 0 & 1 \\ 1 & 3 & 2 \\ 0 & 1 & 1 \end{bmatrix}$:

$$\begin{aligned} \det(A) &= (2)(3)(1) + (0)(2)(0) + (1)(1)(1) - (1)(3)(0) - (2)(2)(1) - (0)(1)(1) \\ &= 6 + 0 + 1 - 0 - 4 - 0 = 3 \end{aligned}$$

En 3×3 , el determinante mide el **volumen** del paralelepípedo (la “caja” inclinada) que forman las tres columnas —la misma idea que en 2×2 , un nivel de dimensión más arriba.

1.5. Propiedades que usaremos después

- $\det(A) = 0 \iff A$ no tiene inversa.
- $\det(AB) = \det(A)\det(B)$.
- $\det(A^\top) = \det(A)$.
- $\det(A)$ es el **producto de todos los autovalores** de A —esta es la conexión que vamos a usar en el siguiente documento.

2. Norma euclidiana

2.1. ¿Qué es?

La norma de un vector es, simplemente, **su longitud** —qué tan “grande” es la flecha que representa. Se denota $\|x\|$.

2.2. Fórmula


Para $x = (x_1, \dots, x_n)$:

$$\|x\| = \sqrt{x_1^2 + x_2^2 + \dots + x_n^2}$$

En 2 dimensiones, esto es literalmente el **teorema de Pitágoras**: la hipotenusa de un triángulo rectángulo con catetos x_1 y x_2 .

Ejemplo. $x = (3, 4)$:

$$\|x\| = \sqrt{3^2 + 4^2} = \sqrt{9 + 16} = \sqrt{25} = 5$$



3. Producto punto (producto interno)

3.1. ¿Qué es?

El producto punto combina dos vectores del mismo tamaño y da como resultado **un solo número** (no un vector). Se denota $x \cdot y$ o $x^\top y$.

3.2. Fórmula

$$x \cdot y = x_1 y_1 + x_2 y_2 + \cdots + x_n y_n$$

Ejemplo. $x = (1, 0)$, $y = (1, 1)$:

$$x \cdot y = (1)(1) + (0)(1) = 1$$

Nota que $x \cdot x = \|x\|^2$ —el producto punto de un vector consigo mismo es su longitud al cuadrado.

3.3. Significado geométrico: mide qué tan alineados están dos vectores

$$x \cdot y = \|x\| \|y\| \cos(\theta)$$

donde θ es el ángulo entre los dos vectores. Despejando, esto nos da una forma directa de **calcular el ángulo** entre dos vectores cualesquiera:

$$\cos(\theta) = \frac{x \cdot y}{\|x\| \|y\|}$$

Ejemplo. Con $x = (1, 0)$, $y = (1, 1)$: ya sabemos $x \cdot y = 1$, $\|x\| = 1$, $\|y\| = \sqrt{2}$.

$$\cos(\theta) = \frac{1}{(1)(\sqrt{2})} = \frac{1}{\sqrt{2}} \approx 0,707 \implies \theta = 45^\circ$$

3.4. El caso especial: producto punto igual a cero

Si $x \cdot y = 0$, entonces $\cos(\theta) = 0$, es decir $\theta = 90^\circ$: los vectores son **perpendiculares**. Esto es tan útil que tiene su propio nombre: **ortogonalidad**.

Ejemplo. $x = (2, 3)$, $y = (3, -2)$: $x \cdot y = (2)(3) + (3)(-2) = 6 - 6 = 0$ —son ortogonales (perpendiculares), sin necesidad de dibujarlos para comprobarlo.

4. Ortogonalidad y matrices ortogonales

4.1. Vectores ortogonales, unitarios y ortonormales

- Dos vectores son **ortogonales** si $x \cdot y = 0$ (perpendiculares).
- Un vector es **unitario** si $\|x\| = 1$ (longitud exactamente 1). Cualquier vector se puede **normalizar** —convertir en unitario sin cambiar su dirección— dividiéndolo entre su propia norma:
$$\hat{x} = \frac{x}{\|x\|}.$$
- Un conjunto de vectores es **ortonormal** si todos son unitarios y ortogonales entre sí.

4.2. Matriz ortogonal

Una matriz cuadrada A es **ortogonal** si sus columnas forman un conjunto ortonormal. Esto se resume en una condición muy compacta:

$$A^\top A = I$$

Ejemplo: una matriz de rotación de 90° .

$$R = \begin{bmatrix} 0 & -1 \\ 1 & 0 \end{bmatrix}$$

Sus columnas son $(0, 1)$ y $(-1, 0)$: ambas tienen norma 1, y su producto punto es $(0)(-1) + (1)(0) = 0$ —ortonormales. Verificando la condición:

$$R^\top R = \begin{bmatrix} 0 & 1 \\ -1 & 0 \end{bmatrix} \begin{bmatrix} 0 & -1 \\ 1 & 0 \end{bmatrix} = \begin{bmatrix} 1 & 0 \\ 0 & 1 \end{bmatrix} = I \quad \checkmark$$

4.3. La propiedad más útil: no hace falta Gauss-Jordan para invertirla

Si A es ortogonal, su inversa es simplemente su transpuesta:

$$A^{-1} = A^\top$$

(Se obtiene directo de $A^\top A = I$: por definición de inversa, eso significa que $A^\top$ ya es el inverso de A .)

Para la matriz de rotación de arriba, $R^{-1} = R^\top = \begin{bmatrix} 0 & 1 \\ -1 & 0 \end{bmatrix}$ —ni una sola operación de eliminación fue necesaria.

5. Ejercicios propuestos

5.1. Determinante

Ejercicio 1. Calcula $\det(A)$ para $A = \begin{bmatrix} 5 & 2 \\ 3 & 4 \end{bmatrix}$ e indica si A tiene inversa.

Solución. $\det(A) = (5)(4) - (2)(3) = 20 - 6 = 14$. Como $14 \neq 0$, A **sí** tiene inversa.

Ejercicio 2. ¿Es $C = \begin{bmatrix} 2 & 6 \\ 1 & 3 \end{bmatrix}$ invertible?

Solución. $\det(C) = (2)(3) - (6)(1) = 6 - 6 = 0$. **No** es invertible (y, en efecto, la columna 2 es 3 veces la columna 1: son dependientes).

5.2. Norma y producto punto

Ejercicio 1. Calcula $\|x\|$ para $x = (6, 8)$.

Solución. $\|x\| = \sqrt{36 + 64} = \sqrt{100} = 10$.

Ejercicio 2. Calcula el ángulo entre $x = (1, 0)$ y $y = (1, \sqrt{3})$.

Solución. $x \cdot y = 1$, $\|x\| = 1$, $\|y\| = \sqrt{1 + 3} = 2$. $\cos(\theta) = \frac{1}{2} \Rightarrow \theta = 60^\circ$.

5.3. Ortogonalidad

Ejercicio 1. ¿Son ortogonales $x = (4, -1)$ y $y = (1, 4)$?

Solución. $x \cdot y = (4)(1) + (-1)(4) = 4 - 4 = 0$. **Sí**, son ortogonales.

Ejercicio 2. Normaliza el vector $x = (3, 4)$ (encuentra el vector unitario en su misma dirección).

Solución. $\|x\| = 5$, así que $\hat{x} = \left(\frac{3}{5}, \frac{4}{5}\right) = (0,6, 0,8)$. Verificación: $\|\hat{x}\| = \sqrt{0,36 + 0,64} = \sqrt{1} = 1$ ✓.

6. Aplicaciones en Inteligencia Artificial y Machine Learning

6.1. Producto punto: similitud del coseno y mecanismos de atención

La **similitud del coseno** —qué tan parecidas son dos representaciones vectoriales (dos embeddings, dos documentos, dos imágenes)— es exactamente $\cos(\theta) = \frac{x \cdot y}{\|x\| \|y\|}$: el producto punto normalizado por las normas. Es la métrica más usada para comparar embeddings en sistemas de recomendación y búsqueda semántica. Más aún, el mecanismo de **atención** en los Transformers (la arquitectura detrás de los modelos de lenguaje actuales) calcula, en su primer paso, el producto punto entre vectores de “consulta” y “clave” para decidir en qué partes de la entrada enfocarse.

6.2. Norma: regularización de modelos

La regularización L_2 (o *weight decay*), una de las técnicas más comunes para evitar el sobreajuste, penaliza la norma euclidiana de los pesos del modelo, agregando $\lambda \|\theta\|^2$ a la función de pérdida —literalmente el mismo $\|\cdot\|^2 = x \cdot x$ que acabamos de definir.

6.3. Matrices ortogonales: estabilidad en redes neuronales profundas

Inicializar (o restringir) las matrices de pesos de una red neuronal para que sean ortogonales ayuda a evitar que los gradientes “exploten” o “desaparezcan” durante el entrenamiento, porque las transformaciones ortogonales **preservan la norma** de los vectores que transforman (no los estiran ni los encogen, solo los rotan o reflejan). Esta es una de las razones detrás de técnicas como la inicialización ortogonal de pesos en redes recurrentes.

6.4. Determinante: modelos generativos (*normalizing flows*)

Ya lo mencionamos antes: los *normalizing flows* necesitan transformaciones invertibles. Pero además, para evaluar la densidad de probabilidad correctamente, necesitan el **determinante del Jacobiano** de cada transformación —el mismo concepto de “factor de escalamiento de volumen” que vimos en este documento, aplicado a transformaciones más generales que las lineales.