

Autovalores y Autovectores

Matemáticas para Inteligencia Artificial — Unidad I

Índice

1. ¿Qué son los autovalores y autovectores?	2
1.1. La idea, en una frase	2
1.2. Definición	2
1.3. Interpretación geométrica	2
2. Cómo encontrar los autovalores: el polinomio característico	3
2.1. De dónde sale la fórmula	3
3. Ejemplo completo, paso a paso	3
4. Un segundo ejemplo: matrices simétricas	4
5. Propiedades según el tipo de matriz	4
5.1. Matrices simétricas ($A^T = A$)	4
5.2. Matrices ortogonales ($A^T A = I$)	4
6. Relación con la diagonalización	4
6.1. La idea	4
6.2. El caso simétrico	5
6.3. ¿Para qué sirve diagonalizar?	5
7. Ejercicios propuestos	6
8. Aplicaciones en Inteligencia Artificial y Machine Learning	6
8.1. Análisis de Componentes Principales (PCA)	6
8.2. Estabilidad de sistemas dinámicos	6
8.3. Método de la potencia: cómo se calculan autovalores en la práctica	6

Basado en: Deisenroth, M. P., Faisal, A. A., & Ong, C. S. (2020). Mathematics for Machine Learning. Cambridge University Press, Secciones 4.1–4.4.

Este documento usa determinante, norma, producto punto y ortogonalidad —si necesitas repasarlos, están en el documento 03.

1. ¿Qué son los autovalores y autovectores?

1.1. La idea, en una frase

Cuando multiplicas una matriz A por un vector x cualquiera, el resultado Ax generalmente **apunta en una dirección distinta** a la de x . Pero para ciertas direcciones muy especiales, algo curioso pasa: Ax termina apuntando **exactamente en la misma dirección** que x (o en la dirección opuesta) —solo cambia su tamaño. A esos vectores especiales se les llama **autovectores**, y al factor por el que se estiran o encogen, **autovalor**.

1.2. Definición

$v \neq \mathbf{0}$ es un **autovector** de A con **autovalor** λ si:

$$Av = \lambda v$$


Es decir: multiplicar v por la matriz A da exactamente lo mismo que multiplicar v por el número λ .

Notación formal. Sea $A \in \mathbb{R}^{n \times n}$. Decimos que $\lambda \in \mathbb{R}$ es un **autovalor** de A y $v \in \mathbb{R}^n \setminus \{\mathbf{0}\}$ es su **autovector** correspondiente si $Av = \lambda v$.

Aquí $A \in \mathbb{R}^{n \times n}$ dice que A es una matriz cuadrada de tamaño n ; $\lambda \in \mathbb{R}$ dice que el autovalor es un número real; y $v \in \mathbb{R}^n \setminus \{\mathbf{0}\}$ dice que v es un vector de n entradas, **excluyendo** el vector cero (el símbolo $\setminus$ es resta de conjuntos: “todo $\mathbb{R}^n$, menos el vector cero”). Se excluye $\mathbf{0}$ porque si se permitiera, la ecuación se cumpliría siempre, para cualquier A y cualquier λ —la definición perdería sentido.

1.3. Interpretación geométrica

Con $A = \begin{bmatrix} 4 & 1 \\ 2 & 3 \end{bmatrix}$: el vector $v = (1, 1)$ es un autovector con autovalor 5 (lo vamos a comprobar en un momento). Compáralo con un vector cualquiera, $w = (1, 0)$, que **no** es autovector:



Av cae exactamente sobre la misma línea que v (solo 5 veces más largo). En cambio Aw apunta en una dirección totalmente distinta a w —por eso w no es autovector. La mayoría de los vectores se comportan como w ; solo direcciones muy particulares se comportan como v .

2. Cómo encontrar los autovalores: el polinomio característico

2.1. De dónde sale la fórmula

Partimos de $Av = \lambda v$ y pasamos todo al mismo lado:

$$Av - \lambda v = \mathbf{0} \implies (A - \lambda I)v = \mathbf{0}$$

(Aquí I es la matriz identidad —se necesita porque λ es un número y A es una matriz; no se pueden restar directamente. λI sí es una matriz, del mismo tamaño que A .)

Buscamos un vector $v \neq \mathbf{0}$ que resuelva esto. Pero ya sabemos (del documento de requisitos previos) que un sistema homogéneo $(A - \lambda I)v = \mathbf{0}$ tiene soluciones distintas de $\mathbf{0}$ **únicamente** cuando la matriz $(A - \lambda I)$ es singular, es decir, cuando su determinante es cero. Esa es la condición que define los autovalores:

$$\det(A - \lambda I) = 0$$

A esta expresión (un polinomio en λ) se le llama **polinomio característico**. Sus raíces son los autovalores de A .

3. Ejemplo completo, paso a paso

$$A = \begin{bmatrix} 4 & 1 \\ 2 & 3 \end{bmatrix}$$

Paso 1: plantear $A - \lambda I$.

$$A - \lambda I = \begin{bmatrix} 4 - \lambda & 1 \\ 2 & 3 - \lambda \end{bmatrix}$$

Paso 2: calcular el determinante e igualar a cero.

$$\det(A - \lambda I) = (4 - \lambda)(3 - \lambda) - (1)(2) = 12 - 7\lambda + \lambda^2 - 2 = \lambda^2 - 7\lambda + 10$$

$$\lambda^2 - 7\lambda + 10 = 0 \implies (\lambda - 5)(\lambda - 2) = 0 \implies \lambda = 5 \text{ o } \lambda = 2$$

Paso 3: encontrar el autovector de cada autovalor. Para cada λ , resolvemos $(A - \lambda I)v = \mathbf{0}$ (exactamente como resolvíamos espacios nulos).

Con $\lambda = 5$:

$$\begin{bmatrix} 4 - 5 & 1 \\ 2 & 3 - 5 \end{bmatrix} v = \begin{bmatrix} -1 & 1 \\ 2 & -2 \end{bmatrix} v = \mathbf{0} \implies -v_1 + v_2 = 0 \implies v_1 = v_2$$

$$v = (1, 1) \text{ (o cualquier múltiplo)}$$

Con $\lambda = 2$:

$$\begin{bmatrix} 4 - 2 & 1 \\ 2 & 3 - 2 \end{bmatrix} v = \begin{bmatrix} 2 & 1 \\ 2 & 1 \end{bmatrix} v = \mathbf{0} \implies 2v_1 + v_2 = 0 \implies v_2 = -2v_1$$

$$v = (1, -2) \text{ (o cualquier múltiplo)}$$

Verificación. $Av = \begin{bmatrix} 4 & 1 \\ 2 & 3 \end{bmatrix} \begin{bmatrix} 1 \\ 1 \end{bmatrix} = \begin{bmatrix} 5 \\ 5 \end{bmatrix} = 5 \begin{bmatrix} 1 \\ 1 \end{bmatrix} \checkmark$, y $\begin{bmatrix} 4 & 1 \\ 2 & 3 \end{bmatrix} \begin{bmatrix} 1 \\ -2 \end{bmatrix} = \begin{bmatrix} 2 \\ -4 \end{bmatrix} = 2 \begin{bmatrix} 1 \\ -2 \end{bmatrix} \checkmark$.

Nota: cada autovector realmente representa una **dirección completa** (una línea que pasa por el origen), no un único vector —cualquier múltiplo suyo también es autovector con el mismo autovalor. Al conjunto de todos esos múltiplos (más el vector **0**) se le llama **espacio propio** o *eigenspace* de ese autovalor, y es, otra vez, un subespacio vectorial.

4. Un segundo ejemplo: matrices simétricas

$$A = \begin{bmatrix} 2 & 1 \\ 1 & 2 \end{bmatrix} \quad (\text{simétrica: } A^T = A)$$

Siguiendo el mismo procedimiento: $\det(A - \lambda I) = (2 - \lambda)^2 - 1 = 0 \Rightarrow \lambda = 3$ o $\lambda = 1$. Los autovectores resultan ser $v_1 = (1, 1)$ (para $\lambda = 3$) y $v_2 = (1, -1)$ (para $\lambda = 1$). Calculemos su producto punto:

$$v_1 \cdot v_2 = (1)(1) + (1)(-1) = 0$$

¡Son **ortogonales**! Esto no es casualidad.

5. Propiedades según el tipo de matriz

5.1. Matrices simétricas ($A^T = A$)

- Todos sus autovalores son **números reales** (nunca complejos).
- Sus autovectores (de autovalores distintos) son siempre **ortogonales** entre sí, como acabamos de ver.

5.2. Matrices ortogonales ($A^T A = I$)

- Todos sus autovalores tienen $|\lambda| = 1$ (pueden ser complejos, pero su “tamaño” siempre es 1).
- Intuición geométrica: una matriz ortogonal representa una rotación (o una reflexión). Una rotación (distinta de 0° o 180°) **no tiene ninguna dirección real que se quede fija** —gira **todos** los vectores— y por eso, en general, no tiene autovectores reales.

6. Relación con la diagonalización

6.1. La idea

Si juntamos los autovectores de A como columnas de una matriz P , y ponemos los autovalores correspondientes en la diagonal de una matriz D , se cumple:

$$A = PDP^{-1}$$

Ejemplo (con la matriz de la Sección 3). $P = \begin{bmatrix} 1 & 1 \\ 1 & -2 \end{bmatrix}$ (columnas = autovectores), $D = \begin{bmatrix} 5 & 0 \\ 0 & 2 \end{bmatrix}$ (autovalores en la diagonal, en el mismo orden). Se puede verificar que $PDP^{-1} = \begin{bmatrix} 4 & 1 \\ 2 & 3 \end{bmatrix} = A$ —exactamente la matriz original.

6.2. El caso simétrico

Si A es simétrica, sus autovectores son ortogonales (Sección 5); normalizándolos (dividiendo cada uno entre su norma), P se vuelve una matriz **ortogonal**. Y ya vimos en el documento anterior que para una matriz ortogonal, $P^{-1} = P^{\top}$ —¡no hace falta invertir nada!

$$A = PDP^{\top}$$

6.3. ¿Para qué sirve diagonalizar?

Calcular potencias de A se vuelve trivial: $A^k = PD^kP^{-1}$, y elevar una matriz **diagonal** a la potencia k es solo elevar cada número de la diagonal —muchísimo más barato que multiplicar A por sí misma k veces.

7. Ejercicios propuestos

Ejercicio 1. Encuentra los autovalores y autovectores de $A = \begin{bmatrix} 3 & 0 \\ 0 & 5 \end{bmatrix}$.

Solución. Como A ya es diagonal, $\det(A - \lambda I) = (3 - \lambda)(5 - \lambda) = 0 \Rightarrow \lambda = 3, 5$. Para $\lambda = 3$: $v = (1, 0)$. Para $\lambda = 5$: $v = (0, 1)$. (Para una matriz diagonal, los autovalores son directamente los números de la diagonal, y los autovectores son los vectores canónicos.)

Ejercicio 2. Encuentra los autovalores de $A = \begin{bmatrix} 1 & 2 \\ 2 & 1 \end{bmatrix}$ y verifica que sus autovectores son ortogonales.

Solución. $\det(A - \lambda I) = (1 - \lambda)^2 - 4 = 0 \Rightarrow (1 - \lambda) = \pm 2 \Rightarrow \lambda = -1, 3$.

Con $\lambda = 3$: $\begin{bmatrix} -2 & 2 \\ 2 & -2 \end{bmatrix} v = 0 \Rightarrow v_1 = v_2 \Rightarrow v = (1, 1)$.

Con $\lambda = -1$: $\begin{bmatrix} 2 & 2 \\ 2 & 2 \end{bmatrix} v = 0 \Rightarrow v_1 = -v_2 \Rightarrow v = (1, -1)$.

$v_1 \cdot v_2 = (1)(1) + (1)(-1) = 0$ ✓ ortogonales (como se espera, A es simétrica).

Ejercicio 3. Usando los resultados del Ejemplo de la Sección 3 ($A = \begin{bmatrix} 4 & 1 \\ 2 & 3 \end{bmatrix}$, $\lambda = 5, 2$), calcula $\det(A)$ usando la propiedad “ $\det(A)$ es el producto de los autovalores”, y verifica contra el cálculo directo.

Solución. Producto de autovalores: $5 \times 2 = 10$. Cálculo directo: $\det(A) = (4)(3) - (1)(2) = 12 - 2 = 10$ ✓.

8. Aplicaciones en Inteligencia Artificial y Machine Learning

8.1. Análisis de Componentes Principales (PCA)

PCA calcula los autovectores y autovalores de la **matriz de covarianza** de los datos. Los autovectores indican las **direcciones** en las que los datos varían más; los autovalores indican **cuánta** varianza hay en cada una de esas direcciones. Como la matriz de covarianza siempre es simétrica, sus autovectores son ortogonales entre sí —por eso las componentes principales de PCA nunca se traslapan en información.

8.2. Estabilidad de sistemas dinámicos

En un sistema que evoluciona en el tiempo mediante $x_{t+1} = Ax_t$ (por ejemplo, el estado interno de una red neuronal recurrente en cada paso), el comportamiento a largo plazo depende **por completo** de los autovalores de A : si todos tienen $|\lambda| < 1$, el sistema converge a cero (estable); si algún $|\lambda| > 1$, el sistema explota (inestable). Esta es precisamente la razón detrás del problema de gradientes que explotan o desaparecen en redes neuronales recurrentes.

8.3. Método de la potencia: cómo se calculan autovalores en la práctica

Para matrices grandes, resolver el polinomio característico directamente es computacionalmente costoso. El **método de la potencia** (*power iteration*) encuentra el autovalor dominante (el de mayor $|\lambda|$) de forma iterativa: se parte de un vector cualquiera x_0 y se calcula repetidamente $x_{k+1} = Ax_k$; la dirección de x_k converge al autovector dominante.

Ilustración con $A = \begin{bmatrix} 4 & 1 \\ 2 & 3 \end{bmatrix}$ (autovector dominante esperado: $(1, 1)$), partiendo de $x_0 = (1, 0)$:

Iteración	x_k	Normalizado (entrada mayor = 1)
1	(4, 2)	(1, 0.500)
2	(18, 14)	(1, 0.778)
3	(86, 78)	(1, 0.907)
4	(422, 406)	(1, 0.962)
5	(2094, 2062)	(1, 0.985)

La segunda coordenada se acerca cada vez más a 1 —convergiendo exactamente a la dirección $(1, 1)$, el autovector dominante que ya habíamos calculado analíticamente. Este método (y sus variantes) es la base de algoritmos como **PageRank** de Google, que encuentra el autovector dominante de una matriz gigante que describe los enlaces entre páginas web.